

Vliv domovských států na výsledky týmů NHL

Úvod

Cílem této práce je zkoumat vliv různých aspektů souvisejících s umístěním týmů NHL na jejich výsledky. Konkrétně se zaměřením na následující kritéria, stát v němž daný tým sídlí, tedy porovnání amerických a kanadských týmů, hokejové tradice v daném městě/oblasti a daňová zátěž klubu.

Ještě než přejdeme k podrobnějšímu popisu dat a jejich zpracování, tak by bylo vhodné podrobněji definovat výše zmíněná kritéria a nastínit způsob zkoumání jejich vlivu na výsledky jednotlivých týmů.

Obecným postupem zkoumání vlivu daných aspektů na výkony týmu, bude tými rozdělit do dvou a více skupin dle daného kritéria, a následně se pomocí statistického testování hypotéz pokusit zamítnout nulovou hypotézu, že rozřazení týmů do skupin nemá vliv na jejich výsledky. Konkrétně za použití dvouvýběrového t-testu a p-wermutačního testu. Konkrétní použití těchto testů a způsob vyjádření úspěšnosti jednotlivých týmů bude popsáno v následujících kapitolách.

První z kritérií, tedy rozdělení na americké a kanadské týmy, není třeba blíže specifikovat. Rozdělení týmů jednoznačně určuje stát v němž sídlí. Druhé kritérium, tedy hokejová tradice v dané oblasti, už není tak jednoznačné, proto definujeme toto kritérium tak, že za tradiční budou považovány všechny týmy, které NHL hrály před jejím prvním velkým rozšířením v roce 1970. Tedy s výjimkou týmu Minnesota Wild, který bude považován za nástupce tradičního týmu Minnesota North Stars, přestože čistě formálně by jím měl být tým Dallas Stars, ale z hlediska hokejové tradice na něj navázal spíše právě tým Minnesota Wild¹. Posledním z kritérií je pak daňové zatížení klubů. Při rozdělení týmů dle tohoto kritéria byla využita data o průměrné daňové sazbě použité při danění ročních příjmů hráče v daném klubu (konkrétně průměrná daňová sazba při danění ročního příjmu 3 milionů dolarů v roce 2026, pozn.: roční příjem 3 miliony dolarů byl zvolen jako referenční hodnota na základě informací o mediánovém a průměrném příjmu hráče NHL, průměr se pohybuje mezi 3 a 4 miliony, medián pak mezi 2 a 3 miliony). Konkrétně týmy pro jejichž hráče byla průměrná daňová sazba pod 40%, byly zařazeny do kategorie nízká daňová zátěž. Týmy s průměrnou daňovou sazbou mezi 40% a 46% z příjmu byly zařazeny do kategorie střední daňová zátěž. Ostatní týmy s průměrnou daňovou zátěží vyšší než 46% pak byly zařazeny do kategorie vysoká daňová zátěž.

Použitá data a jejich zpracování

Za tímto účelem jsou v práci samostatně zpracovávány data s výsledky jednotlivých klubů v základní a vyřazovací části soutěže. Použita data jsou z časového období od roku 2005 do roku 2026, rok 2005 byl zvolen z důvodu, že v tomto roce byl v rámci NHL zaveden platový strop, který značně ovlivnil podobu soutěže.

Data o výsledcích základní a vyřazovací části mají podobu tabulky, kde každý řádek představuje jeden tým a jednotlivé sloupce pak jednu z řady sledovaných statistik (počet odehraných utkání, počet bodů, počet gólů, ...). Z hlediska zpracování dat v rámci tohoto projektu jsou pro nás zajímavé pouze sloupce udávající počet výhře při analýze playoff části. A počet získaných bodů spolu s počtem odehraných utkání pro část základní. Zdrojem dat o výsledcích jednotlivých sezón soutěže je stránka Hockey-Reference. Pro lepší replikovatelnost uváděných výsledků je v rámci projektu využívána lokální kopie dat z července 2026, která je součástí tohoto repozitáře. Pro stažení aktuálních dat o výsledcích playoff z Hockey-Reference lze využít skript `data_import.py` v podadresáři `tools`. Import dat o základní části soutěže je z důvodu vyšší pracnosti nutné provést ručně stažením `.xls` souboru ze stránky Hockey-Reference pro danou sezonu (zde příklad pro sezonu 2025-2026)


Zmíněná data o průměrné daňové zátěži pak pochází z PuckPedia Tax Calculator. Data použitá v rámci projektu lze opět nalézt v lokální kopii z července 2026 v `resources/tax_burden.html`. Obsahem souboru je HTML tabulka vygenerovaná PuckPedia Tax Calculator pro roční příjem 3 miliony dolarů, která je pro přehlednost pouze manuálně očištěna od nedatových elementů. Rozdělení týmů do skupin dle daňové zátěže

¹Problém s přesunem, nebo zánikem/vznikem týmu se v rámci sledovaného období vyskytuje několikrát, obecnou metodikou je v tomto případě, že pokud tým zůstal působit ve stejné oblasti a pouze změnil název/majitele, pak jsou oba týmy sloučeny pod nově vzniklý tým (například Mighty Ducks of Anaheim a Anaheim Ducks jsou v rámci proce sloučeny jako Anaheim Duck). Pokud se však tým přesunul a začal působit ve zcela jiné oblasti, je rozdělen na dva nezávislé týmy (jeden po přesunu vznikl a druhý zanikl, například Atlanta Thrashers a Winnipeg Jets). Pokud tým vznikl/zanikl v průběhu sledovaného období bez předchůdce/pokračovatele je v práci zahrnut jako standardní tým, ale pouze po dobu své existence (například Seattle Kraken).

na základě těchto dat je opět provedeno manuálně (manuální rozřazení týmů je rychlejší než automatizace celého procesu), viz. `src/teams_division.py`

Jak již bylo zmíněno, na základě údajů o počtu získaných bodů a vyhraných zápasů je vypočítávána veličina kvantifikující úspěšnost jednotlivých týmů. V případě analýzy základní části soutěže je touto veličinou prostý procentuální podíl bodů získaných týmem v průběhu sezóny z celkově možných. V případě vyřazovací části soutěže je veličinou vyjadřující úspěšnost týmu počet vyhraných kol vyřazovací části (plus jeden bod této metriky pro každý tým, jenž do playoff postoupil, aby došlo k odlišení týmu, jenž byly vyřazeny v prvním kole a týmů, jenž vůbec nepostoupili, a eliminaci tohoto typu survivorship bias).

Závěrem ještě přidejme vizualizaci výkonu týmu v jednotlivých částech soutěže při rozdělení dle zmíněných kritérií.



Obrázek 1: Výkon týmu v základní části při rozdělení dle jednotlivých aspektů


Použité statistické metody

Jak již bylo řečeno, obecnou metodou zkoumání vlivů jednotlivých atributů je rozdělit týmy do skupin dle daných parametrů a následně se pomocí testování hypotéz pokusit zamítnout nulovou hypotézu, že rozřazení týmu do skupin nemá vliv na jejich herní výsledky a to s použitím dvou základních statistických testů, dvouvýběrového t-testu a permutačního testu.

Základními předpoklady pro použití t-testu je jednak spojitost testovaných dat a zároveň jejich normálnost. Dále by jednotlivé prvky/měření v datasetu, na něž test používáme, měly být nezávislé. V případě klasického studentova t-testu by obě skupiny, jenž pomocí testu porovnáváme, také měly mít stejný rozptyl.

V rámci práce je dvouvýběrový t-test použit pouze pro analýzu základní části soutěže, protože pro playoff část není vhodný už z důvodu, že náhodná veličina používaná pro vyjádření úspěšnosti týmů v playoff je diskretní a nikoliv spojitá. Při analýze základní části pak t-test není vhodný ani pro případ, kdy zkoumáme vlivu daňové zátěže na výkony týmů, protože zde porovnáváme více než dvě skupiny.

Způsob aplikace dvouvýběrového t-testu v rámci projektu tedy splňuje většinu požadovaných předpokladů, vzhledem k velkému počtu týmu a časovému rozsahu vstupních dat z centrální limitní věty předpokládat, že



Obrázek 2: Výkon týmu ve vyřazovací části při rozdělení dle jednotlivých aspektů

data se v limitě v distribuci blíží normálnímu rozdělení, projekt pak dále namísto klasického Studentova t-testu používá Welchův t-test, čímž odpadá požadavek na shodu v rozptýlu porovnávaných skupin. Procentuální počet získaných bodů používaný jako metrika úspěšnosti je pak spojitou veličinou. Není však zcela splněn předpoklad nezávislosti jednotlivých měření, kdy se dá předpokládat, že pokud byl některý z týmu silný/slabý v jedné sezóně, tak se tento trend promítne i do sezóny následující (tým si ponechá většinu hráčů a dalšího zázemí, jenž ho vedlo k úspěchu/neúspěchu atd.).

V případě permutačního testu je pak v rámci projektu využíváno několik jeho variant, respektive několik testových statistik. Základním případem je permutační test, kde se jako testová statistika použít f-statistika (což je vlastně případ ANOVA). Tento způsob testování je použit pro analýzu vlivu daňové zátěže v případě základní části soutěže. Stejně jako v případě t-testu zde narážíme na problém s tím, že data z jednotlivých sezón nemusí být zcela nezávislá. Splnění druhého z klíčových předpokladů tohot testu, tedy zaměnitelnost skupin za platnosti nulové hypotézy plyne přímo z definice naší analýzy.

Další je permutační test v rámci projektu použit v kombinaci s Kruskalovu statistikou jako alternativu k f-statistice pro případ analýzy vlivu daňové zátěže v playoff fázi, kdy f-statistiku nelze použít z důvodu nespojitosti náhodné veličiny používané k vyjádření úspěšnosti jednotlivých týmů (diskrétní počet vyhraných kol). A také v kombinaci s Mann-Whitneyho U statistikou jako testovou statistikou jako náhrada dvouvýběrového t-testu při porovnání kanadských a amerických a tradičních a nových týmů v playoff (t-test v tomto případě nelze použít, protože diskrétní veličina počtu vyhraných kol vyjadřující úspěšnost v playoff není spojitá a z normálního rozdělení).

Stejně jako v případě s f-statistikou narážejí i tyto bezparametrické varianty na stejný problém s nezávislostí dat z jednotlivých sezón. Předpoklad zaměnitelnosti skupin pod nulovou hypotézou je opět splněn z definice experimentu.

Výsledky experimentů

Základní část

Název experimentu	Statistická metoda	P-hodnota	Testová statistika
Kanada x USA	dvouvýběrový t-test	0.074	-1.79
Tradiční x Expanzní	dvouvýběrový t-test	0.026	2.239
Dle daňové zátěže	permutační test s f-statistikou	0.310	1.146

Tabulka výše shrnuje výsledky jednotlivých experimentů s daty o výsledcích základní části NHL za sezóny 2005-2006 až 2025-2026. Z výsledku vyplývá, že nulovou hypotézu, že rozřazení do jednotlivých skupin neovlivňuje výsledky týmů, můžeme na hranici významnosti 5% zamítnout pouze v případě experimentu, v němž byly porovnávány výsledky tradičních a expanzních týmů. V tomto případě jsme dostali výslednou p-hodnotu 0.026 a hodnotu testové statistiky 2.239. Pokud by tedy platila nulová hypotéza a to, zda je daný tým tradiční, či expanzní nemělo vliv na jeho výsledky, pak budeme pozorovat takové, nebo větší rozdíly ve výsledcích mezi týmy z daných skupin, s pravděpodobností 2,6%. Na základě kladné hodnoty testové statistiky pak můžeme říct, že první skupina, tedy tradiční týmy vzniklé před rokem 1970, dosahovaly v posledních 20 letech v průměru lepších výsledků v základní části soutěže, než nově vzniklé týmy.

Výsledky provedených testů ve zbylých dvou případech nejsou statisticky významné na hranici 5% a nulovou hypotézu, že rozdělení týmu do skupin dle daňové zátěže, či země původu nemá vliv na jejich výsledky v základní části NHL, tedy v těchto případech nezamítneme. I když v případě porovnání kanadských a amerických bychom mohli říct, že se s výslednou p-hodnotou 0.074 pohybujeme mezi hladinami významnosti 5% a 10%, a tedy na hranici statisticky významného výsledku. A tedy bychom v takovém případě teoreticky mohli zamítnout nulovou hypotézu na hladině významnosti 10%, a na základě záporné hodnoty testové statistiky říci, že americké týmy v průměru dosahovaly v základní části lepších výsledků. Zůstaňme ale u standardní hladiny významnosti pro zamítnutí, tedy hladiny významnosti 5%.

Playoff

Název experimentu	Statistická metoda	P-hodnota	Testová statistika
Kanada x USA	permutační test s Mann-Whitney U-statistikou	0.079	32216.000
Tradiční x Expanzní	permutační test s Mann-Whitney U-statistikou	0.027	52438.000
Dle daňové zátěže	permutační test s Kruskal-Wallisovou H-statistikou	0.601	1.001

Tabulka výše opět shrnuje výsledky jednotlivých provedených experimentů, tentokrát však pro data o vyřazovací části soutěže. Stejně jako v případě základní části v předchozí podkapitole, opět dostáváme výsledky, na jejichž základě můžeme nulovou hypotézu na hladině významnosti 5% zamítnout pouze v případě rozdělení týmu na tradiční a expanzní. V případě experimentů porovnávajících tradiční a expanzní týmy je výsledná p-hodnota dokonce velmi podobná jak v případě základní, tak vyřazovací části soutěže.

I výsledky zbylých dvou experimentů jsou velmi podobné jako v případě analýzy základní části. Kdy nulovou hypotézu, že rozdělení na americké a kanadské týmy nemá vliv na výkon jednotlivých týmů, bychom opět mohli zamítnout na hladině významnosti 10%, nikoliv však na standardní hladině 5% a pohybujeme se tak opět na hranici statisticky významného výsledku (výsledná p-hodnota je i v tomto případě velmi blízko výsledné p-hodnotě analogického testu pro data základní části). V případě rozdělení týmů dle daňové zátěže pak opět stejně jako při analýze základní části nulovou hypotézu nezamítneme. Tento experiment je také jediným, kde se výsledná p-hodnota významně liší (je téměř dvojnásobná) od hodnoty, kterou jsme dostali při analogické analýze dat základní části.

Závěr

Závěrem přejdeme k shrnutí celé výše popsané analýzy vlivu aspektů souvisejících s domovským městem/oblastí na výsledky týmů NHL. V rámci projektu bylo zkoumáno, zda země původu (tedy Kanada, či USA), či

hokejová tradice, nebo daňová zátěž v domovské oblasti týmu ovlivňuje jeho výsledky v rámci NHL. Analýza vlivu těchto aspektů byla provedena zvlášť pro základní a vyřazovací část soutěže na datech za posledních 20 sezón (tedy pro sezóny 2005-2006 až 2025-2026). Obecným rámcem pro zkoumání zdali má dané kritérium vliv na výkon jednotlivých týmů, byl vyslovit nulovou hypotézu, že rozdělení týmů do několika skupin dle daného kritéria nemá vliv na jejich výkon a následně se pomocí statistických testů pokusit tuto hypotézu zamítnout na hladině významnosti 5%.

Na základě provedených testů jsme pak dostali statisticky významný výsledek pouze v případě analýzy vlivu hokejové tradice v dané oblasti, kdy jsme nulovou hypotézu, že rozdělení týmu na tradiční a expanzní nemá vliv na jejich výkon zamítli na hladině významnosti 5% a to, jak v případě analýzy základní, tak vyřazovací části soutěže. V případě zkoumání vlivu země původu se pak výsledky v případě obou částí soutěže pohybovaly na hranici statistické významnosti, kdy bylo možné nulovou hypotézu zamítnout na hladině významnosti 10%, ale nikoliv na hladině významnosti 5%. Pro vliv daňové zátěže pak nebyly statisticky významné výsledky testů ani pro jednu z částí soutěže. Výsledky testů pro jednotlivé aspekty jsou také značně konzistentní napříč oběma částmi ligy, kdy v případě testů zkoumajících vliv země původu a hokejové tradice byl rozdíl mezi p-hodnotami v případě základní a vyřazovací části v řádu tisícín. Pouze v případě daňové zátěže byla výsledná p-hodnota v případě playoff části významně vyšší, než tomu bylo v části základní.

Na úplný závěr ještě uvedme hlavní problémy práce na něž je při interpretaci třeba brát zřetel. Jak již bylo zmíněno výše, asi hlavním problémem, který může ovlivnit výsledky jednotlivých experimentů, že v rámci projektu jsou výsledky týmu v jednotlivých sezónách považovány za nezávislé, což není zcela v souladu s reálnou praxí, kdy se týmy po skončení sezóny od základu nezmění, ale zachovávají si minimálně část svých silných/slabých stránek. Dalším nedostatkem pak může být, že například daňové zatížení jednotlivých týmů se v čase neustále vyvíjí, což v rámci projektu není nijak modelováno a týmy jsou staticky rozřazeny dle stavu v době vzniku práce, tedy léte roku 2026.